

PF3325 – REDES COMPUTACIONALES

Detección de Phishing mediante Redes Neuronales Artificiales

Gabriel Fallas & Valeria Chinchilla

Universidad de Costa Rica • Mayo 2026

Agenda de la Presentación




Motivación

El problema del Phishing y su impacto en la ciberseguridad global.



Estado del Arte

Evolución de las técnicas de detección y trabajos previos.



Marco Teórico


Dataset UCI, arquitectura MLP y técnicas de regularización.

| ¿Qué es el Phishing?

Ataque de Ingeniería Social

Suplantación de identidad digital para engañar usuarios y obtener información confidencial mediante sitios web fraudulentos.

- ✓ **Typosquatting:** paypal.com vs paypal.com
- ✓ **Subdominios:** login-bank.verify.net
- ✓ **IP en URL:** Direcciones sin nombre de dominio.



Impacto Global: Estadísticas

4.8M

ATAQUES EN 2024

Récord histórico de actividad maliciosa registrada por el APWG.

\$2.8B

Pérdidas por BEC en EE.UU.

1.13M

Ataques solo en Q2 2025.

Tendencia: Los ataques son cada vez más rápidos. Un sitio de phishing suele vivir menos de 24 horas antes de ser detectado.

Limitaciones de Métodos Actuales

Listas Negras (Blacklists)

Dependen de reportes manuales. Si el sitio es nuevo, escapa a la detección. No escalan al volumen actual de URLs generadas diariamente.

Heurísticas Manuales

Reglas rígidas (ej. "longitud > 75"). Los atacantes adaptan sus técnicas rápidamente para evadir estas condiciones predefinidas.

Solución: Machine Learning para aprender patrones automáticos.

DEFINICIÓN DEL PROBLEMA

¿Puede una Red Neuronal detectar Phishing con máxima precisión en tiempo real?

Formulación Matemática del Clasificador Binario:

$$f(x) = \begin{cases} 1 & \text{si URL Legítima} \\ 0 & \text{si URL Phishing} \end{cases}$$

Donde $x \in \mathbb{R}^{30}$ representa el vector de características del dataset UCI.

Evolución de la Investigación

2008

ANN Básicas (Basnet et al.)

2012

Ingeniería de Features
(Mohammad)

2014

SSNN Clasificador (Benchmark
UCI)

2019

Deep Reinforcement Learning

2025

Estado del Arte
(Transformers)

Papers Fundacionales

Año	Autor	Enfoque	Resultado
2012	Mohammad et al.	Definición de 17 reglas de extracción mediante JS/PHP	84% Accuracy
2014	Mohammad et al.	Dataset expandido (11,055 URLs) y 30 features	97% (SSNN)
2019	Sahingoz et al.	Random Forest + Procesamiento de Lenguaje (NLP)	97.32% Accuracy
2020	Vrbančič et al.	Benchmark masivo y métodos Ensemble (XGBoost)	97.6% Accuracy

Dataset UCI Phishing Websites

- ✓ **Barra de Direcciones (12):** Longitud URL, HTTPS, IP, Símbolo @, Prefijo/Sufijo.
- ✓ **Anomalías (6):** URL de anclaje, links en tags, formularios a otros dominios.
- ✓ **HTML & JS (5):** Redirecciones, Clic derecho deshabilitado, Iframes ocultos.
- ✓ **Dominios (7):** Antigüedad, DNS, Tráfico web, PageRank.

Codificación Ternaria

Cada característica se evalúa en un rango:


+1: Legítimo

0: Sospechoso

-1: Phishing

Arquitectura de la Red (MLP)

Neural Network Architecture



Componentes del Modelo

- ✓ **Entrada:** 30 neuronas (una por feature).
- ✓ **Ocultas:** Capas densas con activación *ReLU*.
- ✓ **Salida:** Sigmoide para probabilidad binaria.

$$L = - [y \cdot \log (p) + (1 - y) \cdot \log (1 - p)]$$

Función de pérdida: Binary Cross-Entropy

Resultados Preliminares (Base)

Random Forest

97%

SVM (RBF)


95%

Mohammad (2014)

97%



Próximo paso: Estudio ablativo de la red MLP para optimizar profundidad, Dropout y Batch Normalization.



¿Preguntas?

Muchas gracias por su atención.

Gabriel Fallas

UCR – PF3325

Valeria Chinchilla


UCR – PF3325

Image Sources



<https://cdn.activestate.com/wp-content/uploads/2021/02/phishing-detection-with-Python.jpg>

Source: www.activestate.com



https://ik.imagekit.io/upgrad1/abroad-images/imageCompo/images/ChatGPT_Image_Nov_20_2025_03_47_56_PMTT18DE.png

Source: www.upgrad.com